Protocoles et performance du web

Encadrant : **Olivier_Fourmaux,**

Etudiants : **Nils_Barrellon, Ilyas_Benyahia, Sanjai_Varatharajah, Hamza_Oulfid**

Table des matières

1 Cahier des charges

1.1 Description générale

Les protocoles pour acceder au web ont évolué à différents niveaux : IPv4 ou IPv6, TCP ou UDP-QUIC, et HTTP1.1 ou HTTP2 ou HTTP3. Les trafics sont souvent chiffrés, particulièrement avec QUIC/HTTP3, ce qui rend plus complexe leurs études, mais pas impossible grâce aux capacités des analyseurs à utiliser les clés privées que certains clients peuvent leur fournir. Le but de ce projet est de découvrir les protocoles utilisées par les principaux sites, d'en déchiffrer les paramétrages et d'en évaluer la performance.

1.2 Travail à réaliser

Plusieurs travaux aux dates limite échelonnées sont à réaliser :

- Analyse des différentes normes autour du protocole HTTP : recherche bibliographique et étude puis synthèse des documents trouvés,
- Etude des outils/librairies disponibles pour générer du trafic HTTP1.1, HTTP2, HTTP3 en récupérant les clés privées et en déchiffrant la partie contrôle du trafic,
- Réalisation d'un outil crawler qui parcours les sites du top 1000 afin de caractériser le paramétrage de chacun d'entre eux, de fournir des statistiques d'usage et de performance. Pour les mesures de performance, les même sites accessibles via les différentes versions de HTTP seront recherchés et comparés.

Ces différents travaux vont nécessiter l'acquisition de nouvelles compétences, notamment :

- découverte et utilisation de l'interface en ligne **Curl** ;
- apprentissage du logiciel **Zotero** pour la création d'une bibliographie correctement normée ;
- apprentissage de la recherche en ligne et en bibliothèque (à l'aide des tutoriels proposés par la BU).

2 Plan de développement

2.1 Diagramme de Gantt

Ci-dessous le diagramme de Gantt établi à la naissance du projet (début novembre).

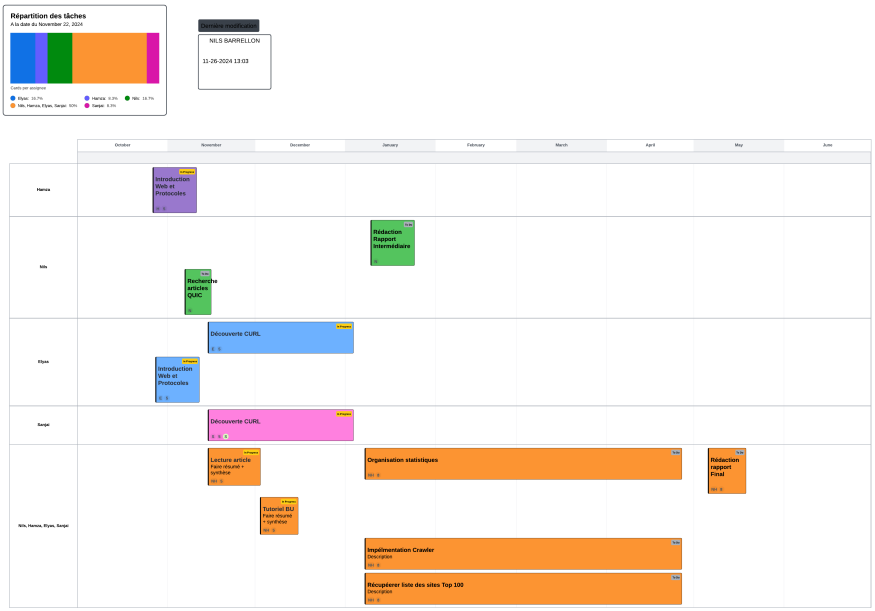

2.2 Fait. A faire

Il nous a semblé judicieux de commencer par une recherche bilbiographique sur le protocole QUIC que nous n'avons pas étudié en cours. Après quelques articles et videos de vulgarisation [1] Le site de recherche de la librairie de l'Association for Computing Machinery nous a permis de trouver une dizaine d'articles concernant le protocole QUIC et ses performances, notamment en comparaison de celles offertes par le protocole TCP. Nous nous sommes répartis la lecture de ces articles, leur résumé et leur synthèse. Dans le même temps, la moitié du groupe s'est lancée dans la découverte de Curl dont nous aurons besoin pour la réalisation du crawler (dont la conception est pour l'instant programmée au deuxième semestre).

Parallèlement, nous avons suivi la formation proposée par la bibliothèque pour l'utilisation de Zotero notamment qui permet l'établissement d'une bibliographie conforme aux normes en vigueur. Nous avons choisi celle de l'IEEF.

3 Bibliographie

Références

[1] Capitole du Libre. *Le protocole QUIC, ou la nouvelle couche de transport — Stéphane Bortzmeyer*. Nov. 2019. url : https://www.youtube.com/watch?v=tJTWaG9VF6c (visité le 20/11/2024).

[2] Wesley Eddy. *Transmission Control Protocol (TCP)*. Request for Comments RFC 9293. Num Pages : 98. Internet Engineering Task Force, août 2022. doi : 10.17487/RFC9293. url : https://datatracker.ietf.org/doc/rfc9293 (visité le 08/12/2024).

[3] Jana Iyengar et Martin Thomson. *QUIC : A UDP-Based Multiplexed and Secure Transport*. Request for Comments RFC 9000. Num Pages : 151. Internet Engineering Task Force, mai 2021. doi : 10.17487/RFC9000. url : https://datatracker.ietf.org/doc/rfc9000 (visité le 06/12/2024).

[4] Fan Liu et Patrick Crowley. "Security and Performance Characteristics of QUIC and HTTP/3". In : *Proceedings of the 10th ACM Conference on Information-Centric Networking*. ACM ICN '23. New York, NY, USA : Association for Computing Machinery, oct. 2023, p. 124-126. isbn : 979-8-4007-0403-1. doi : 10.1145/3623565.3623757. url : https://dl.acm.org/doi/10.1145/3623565.3623757 (visité le 19/11/2024).

[5] Jonas Mücke et al. "ReACKed QUICer : Measuring the Performance of Instant Acknowledgments in QUIC Handshakes". In : *Proceedings of the 2024 ACM on Internet Measurement Conference*. IMC '24. New York, NY, USA : Association for Computing Machinery, nov. 2024, p. 389-400. isbn : 979-8-4007-0592-2. doi : 10.1145/3646547.3689022. url : https://dl.acm.org/doi/10.1145/3646547.3689022 (visité le 19/11/2024).

[6] Naveenraj Muthuraj, Nooshin Eghbal et Paul Lu. "Replication : "Taking a long look at QUIC"". In : *Proceedings of the 2024 ACM on Internet Measurement Conference*. IMC '24. New York, NY, USA : Association for Computing Machinery, nov. 2024, p. 375-388. isbn : 979-8-4007-0592-2. doi : 10.1145/3646547.3688453. url : https://dl.acm.org/doi/10.1145/3646547.3688453 (visité le 19/11/2024).

[7] Alexander Yu et Theophilus A. Benson. "Dissecting Performance of Production QUIC". en. In : *Proceedings of the Web Conference 2021*. Ljubljana Slovenia : ACM, avr. 2021, p. 1157-1168. isbn : 978-1-4503-8312-7. doi : 10.1145/3442381.3450103. url : https://dl.acm.org/doi/10.1145/3442381.3450103 (visité le 27/11/2024).

4 Analyse

4.1 Introduction

Le World Wide Web, plus communément appelé le web, est un système révolutionnaire de documents hypertexte, interconnectés et accessibles via Internet. Il a transformé l'accès, le partage et la diffusion de l'information à l'échelle mondiale.

Le développement du World Wide Web remonte au début des années 1990, lorsque le scientifique britannique Tim Berners-Lee, travaillant au CERN (Organisation Européenne pour la Recherche Nucléaire), a proposé l'idée d'un système d'information distribué. En 1991, Berners-Lee a présenté le premier navigateur web et serveur web, offrant une interface conviviale pour accéder et naviguer dans les documents hypertexte sur Internet. Au cœur du World Wide Web se trouve le protocole de transfert hypertexte (HTTP), qui facilite le transfert de documents hypertexte entre serveurs web et navigateurs. HTTP permet aux utilisateurs de demander et de récupérer des pages web depuis des serveurs distants, rendant possible une navigation fluide entre des documents interconnectés via des hyperliens.

La structure décentralisée et interconnectée du web, basée sur l'hypertexte, encourage un écosystème où les utilisateurs peuvent explorer divers sujets et découvrir de nouvelles sources de connaissance. Cette approche non linéaire marque une rupture avec les médias imprimés traditionnels, où la navigation et l'exploration sont limitées. Avec l'arrivée de navigateurs graphiques tels que Mosaic et Netscape Navigator dans les années 1990, le World Wide Web s'est popularisé, devenant accessible à un large public et entraînant une croissance exponentielle de l'usage d'Internet. Ces navigateurs ont intégré des fonctionnalités telles que les favoris, l'historique et les capacités de recherche, améliorant considérablement l'expérience utilisateur.

4.2 Les protocoles HTTP

Depuis sa création, le protocole HTTP a évolué pour répondre aux besoins croissants en termes de performances, de sécurité et de scalabilité.

- La première version, HTTP/0.9, introduite en 1991, était rudimentaire et permettait seulement de récupérer des pages HTML en texte brut, sans support pour les en-têtes ou des fonctionnalités avancées. En 1996, HTTP/1.0 a apporté une amélioration majeure avec l'introduction des en-têtes HTTP, permettant la gestion des métadonnées et des contenus variés tels que les images et vidéos.

- En 1997, HTTP/1.1 a marqué une étape clé avec des fonctionnalités comme la connexion persistante, qui réutilise la même connexion TCP pour plusieurs requêtes, la prise en charge des requêtes partielles pour les fichiers volumineux, et une meilleure gestion des proxys et caches.

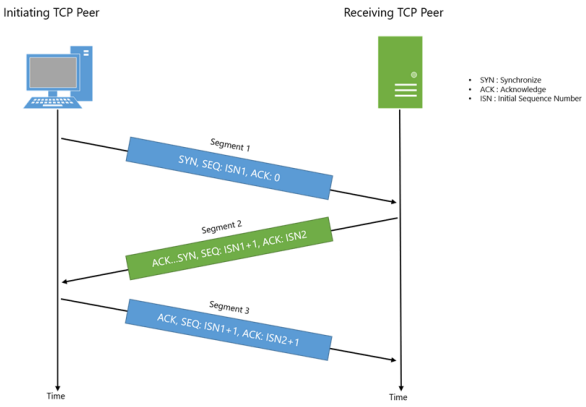

Figure 1 : Protocole TCP. Etablissement de la connexion par 3-Way Handshake

- HTTP/2, introduit en 2015, a été conçu pour améliorer les performances en intégrant des fonctionnalités telles que la multiplexation des requêtes sur une seule connexion, la compression des en-têtes pour réduire la surcharge réseau et le support natif du chiffrement via TLS (bien que non obligatoire).
- Enfin, HTTP/3, basé sur le protocole QUIC et apparu en 2018, a introduit des avancées significatives en utilisant UDP au lieu de TCP, réduisant ainsi la latence, offrant une meilleure gestion des pertes de paquets et rendant les connexions plus robustes. De plus, HTTP/3 impose un chiffrement obligatoire, renforçant la sécurité des communications.

Les normes entourant HTTP, définies par l'IETF (Internet Engineering Task Force), garantissent son interopérabilité et son évolution. Ces normes incluent des RFC détaillant les différentes versions du protocole et leurs extensions associées, assurant ainsi leur mise en œuvre cohérente et efficace à travers le monde.

4.3 Les protocoles de transport

4.3.1 Le protocole TCP

Le protocole TCP voit le jour dans les années 70. Protocole fiable, encapsulé dans un paquet IP, il assure une connexion de bout en bout. A ce jour, il est LE[1] protocole de transport sur Internet. Il a connu de nombreuses améliorations au fil des décennies, en témoignent les Request For Commentsajouter Référence vers dernier RFC TCP nombreuses, la première étant numérotée 761, la dernière 9293[2].

L'établissement d'une connexion TCP, par exemple pour l'obtention d'une page web nécessite le 3-Way HandShake où trois segments SYN, SYN-ACK et ACK sont échangés avant de pouvoir échanger des données.

[1]La finalité de ce travail est de le confirmer ou de l'infirmer

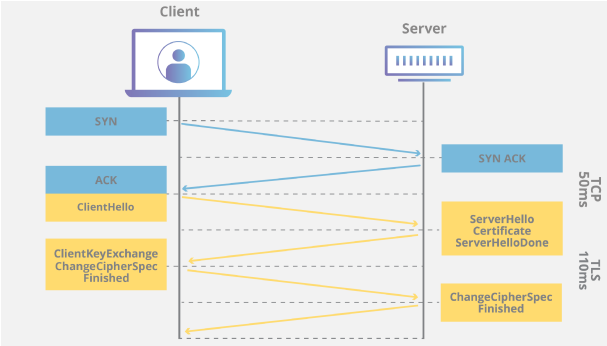

Figure 2 : Protocole TCP avec la couche TLS. Etablissement de la connexion.

La figure 1 [2] montre ainsi que l'établissement de cette connexion a une durée incompressible due au Round Trip Time entre le client et le serveur. Des options comme FastTCP permettant de faire une requête GET simultanément au paquet de synchronisation ont été introduites il y a quelques années mais n'ont jamais résolues le problème car il n'est pas reconnu par les middleboxes qui le bloquent. Par la suite, le besoin de sécurité a imposé de crypter les données contenues dans les segments échangés. Cela a été fait par l'ajout de la couche TLS allongeant les délais de connexion, car au moins deux tours sont nécessaires à son établissement (2-RTT) comme le montre la Figure 2[3].

L'utilisation massive du protocole TCP et son implémentation dans le noyau du système, qui complique grandement les modifications que pourraient apporter la communauté, expliquent son adoption unanime malgré ses problèmes de latence. Ce phénomène met en évidence l'ossification de l'Internet : implémenter un nouveau protocole est très difficile à réaliser...

Néanmoins, dans les années 2010, Google va se lancer dans cette expérimentation car, de nombreux utilisateurs ont adopté le navigateur qu'il a développé (Chrome) pour faire des requêtes sur ses serveurs. L'entreprise étant donc aux deux bouts de la chaine de transport, elle peut implémenter un nouveau protocole de transport appelé QUIC et encapsulé dans UDP. Le HTTP/3 était né : soit la combinaison du protocole HTTP, transporté par QUIC. Il est à noter que, depuis, QUIC est devenu un protocole de transport qui n'est pas uniquement dédié à HTTP, ni aux requêtes de Chrome en direction des serveurs de Google.

4.3.2 Le protocole QUIC

Le protocole QUIC est décrit dans les RFC 8999,9000,9001 et 9002[3].

Étant donné que UDP n'est pas fiable, QUIC implémente les retransmissions et contrôle de congestion dans la couche application.

[2]https ://www.johnpfernandes.com/2018/12/08/the-tcp-3-way-handshake/
[3]https ://www.cloudflare.com/fr-fr/learning/ssl/what-happens-in-a-tls-handshake/

Ce protocole offre un multiplexage amélioré, il permet d'envoyer plusieurs requêtes simultanément sur une seule connexion UDP, éliminant les blocages liés à l'ordre des paquets.

Contrairement à HTTP/1.1 qui nécessite plusieurs RTT pour l'établissement d'une connexion sécurisée, QUIC peut réduire la latence à un seul RTT ou même zéro RTT si le client et le serveur ont déjà échangé auparavant.

QUIC gère aussi son propre algorithme de chiffrement (auparavant géré par TLS) nommé QUIC-Crypto et intègre un module de Correction d'Erreur Avancée (Forward Error Correction, inactif par défaut) pour compenser les pertes dans un groupe de paquets sans devoir retransmettre systématiquement.

QUIC utilise des algorithmes de contrôle de congestion comme CUBIC TCP, mais avec des ajustements spécifiques pour mieux gérer les pertes et maximiser l'utilisation du réseau. Contrairement à TCP, où les connexions sont liées aux adresses IP et aux ports, QUIC utilise un identifiant de connexion unique CID (au niveau de la couche application), facilitant la gestion des changements d'adresses IP, par exemple dans les réseaux mobiles.

4.4 TCP vs QUIC

L'étude de Fan Liu et Patrick Crowley[4] examine les performances de QUIC et HTTP/3 en termes de rapidité, de fiabilité et de gestion des connexions, en les comparant à TCP et HTTP/2.

L'étude s'appuie sur des tests en environnements contrôlés pour évaluer les performances sous différentes conditions réseau. Les ressources testées incluent des fichiers statiques de tailles variées, allant de 0 octet à 10 Mo, ainsi que des pages web réelles provenant de Google, Facebook et Cloudflare, classées par taille (petites, moyennes et grandes). Les serveurs de test utilisent Nginx-quic, tandis que les clients incluent des navigateurs et outils compatibles avec HTTP/2 et HTTP/3, comme Chromium, Curl et Proxygen. Les conditions réseau simulées comportent quatre scénarios : une connexion sans délai ni perte de paquets, une perte de paquets de 5 un délai de 200 ms sans perte, et une combinaison des deux derniers cas. Les performances sont mesurées par le temps jusqu'au dernier octet (TTLB) pour les fichiers simples et l'indice de vitesse (SI) pour les pages web.

Les résultats montrent que QUIC et TCP ont des performances comparables lorsque le réseau est stable, sans délai ni perte. Cependant, lorsque le délai atteint 200 ms, QUIC devient supérieur pour les fichiers inférieurs à 100 Ko, car son handshake rapide réduit l'impact de la latence. Pour les fichiers plus volumineux, cette différence s'atténue. En présence de pertes de paquets, QUIC reste compétitif en ajustant son débit de manière proactive grâce à ses signaux de congestion explicites, contrairement à TCP qui interprète les pertes comme des signes de congestion réseau. Lorsque des pertes de paquets et un délai sont combinés, QUIC dépasse TCP, notamment sur les fichiers de grande taille.

En conclusion, QUIC surpasse TCP dans des environnements dégradés, notamment en cas de faible bande passante, de grande latence ou de perte de paquets

De nombreux autres articles montrent que le protocole QUIC est plus efficace dans la majeure partie des configurations. [5] [6] [7] Ainsi, on peut se demander, comme s'interrogent beaucoup sur le web, si QUIC est amené à supplanter TCP sous peu.

5 Conception

La finalité du projet est de dresser des statistiques sur les 100 sites les plus consultés au monde : quel pourcentage utilise le protocole HTTP/3 ? Il va falloir pour cela étudier les échanges TCP avec ses serveurs. Il conviendra de décrypter les paquets QUIC. Les échanges seront faire en ligne de commande cURL et il faudra les automatiser avec un programme (en bash ? En C ? En python ?). Il faudra peut-être envisager de travailler avec plusieurs navigateurs, QUIC ayant été développé pour Chrome. Ce protocole est-il à l'oeuvre pour des requêtes effectuées depuis un autre navigateur ?

5.1 cURL

5.2 Décryptage

5.3 Liste des 100 sites les plus visités

5.4 Mise en place d'un crawler

Dans quel langage programmer les instructions cURL ?

6 Etat d'avancement/Compte rendu

Fin décembre 2024, l'état d'avancement est le suivant :

- Nous avons mieux cerné le protocole QUIC dont nous ignorions l'existence jusqu'alors. Néanmoins, après lecture d'articles étudiant les principaux avantages de QUIC (notamment par rapport à TCP) nous n'avons pas poussé plus avant son étude et ses mécanismes. En effet, nous avons considéré que cela ne rentrait pas dans le cadre de notre projet.
- Nous avons étudié expérimentalement (à l'aide de captures Wireshark) les connexions du navigateur Chrome sur un serveur de Google (youtube par exemple). L'utilisation de QUIC n'est pas anecdotique.
- Nous avons mieux cerné le projet et ses attendus.
- Les tutoriels de la BU nous ont permis d'entamer la création d'une bibliographie normée à intégrer dans notre rapport. Rapport que nous avons choisi de rédiger en Latex, à l'aide de l'éditeur Tex Maker.

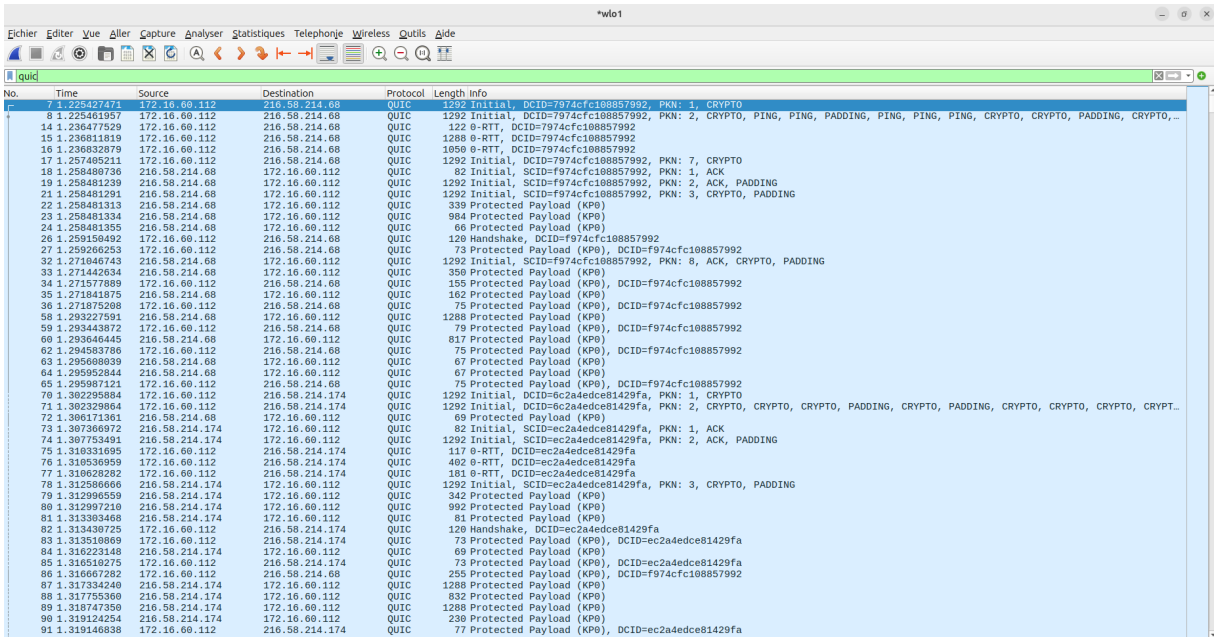

Figure 3 : Capture WireShark. Requête depuis Google Chrome vers Youtube.fr

7 Annexe A

Deux captures d'écran d'une analyse de trames par WireShark lors d'un appel depuis Google Chrome à un serveur Google (youtube.fr).

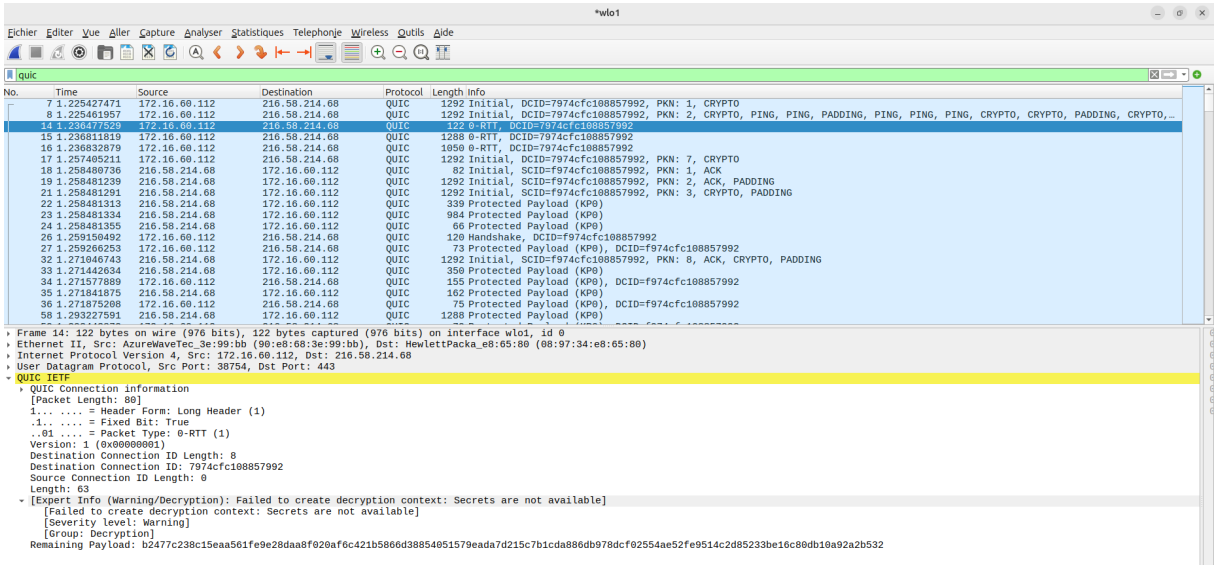

Figure 4 : Capture WireShark. Requête depuis Google Chrome vers Youtube.fr. Zoom 0-RTT